# TAREA FINAL NOSQL

## Temporada ATP 2025

Análisis de los partidos del circuito ATP con MongoDB




**Hugo Lucendo Romero**

**BASES DE DATOS NOSQL**

**05/11/2026**

# Índice

**1. Introducción** **3**

**2. Dataset** **3**
2.1. Origen de los datos . . . 3
2.2. Transformación de CSV a JSON . . . 3
2.3. Estructura de los documentos . . . 4
2.4. Carga en MongoDB . . . 4

**3. Inserción, Actualización, Proyección y Filtrado** **6**
3.1. Traducción de las superficies . . . 6
3.2. Partidos con y sin estadísticas . . . 7
3.3. Colección de niveles de torneo . . . 8
3.4. Inserción, modificación y borrado de un partido . . . 8
3.5. Finales de los Grand Slam . . . 10
3.6. Partidos entre Alcaraz y Sinner . . . 11
3.7. Partidos más largos de la temporada . . . 12
3.8. Consultas sobre el array de sets . . . 12

**4. Pipeline de Agregación** **14**
4.1. Partidos y duración media por superficie . . . 14
4.2. Duración media por superficie y número de sets . . . 15
4.3. Títulos y puntos por jugador . . . 16
4.4. Balance de victorias de todos los jugadores . . . 17
4.5. Porcentaje de sets que acaban en tiebreak por superficie . . . 19
4.6. Aces según la altura del jugador . . . 19
4.7. Victorias de Alcaraz y Sinner por mes . . . 21

**5. Visualización con Python** **22**

**6. Conclusiones** **25**

# 1 Introducción

En este trabajo se analiza la temporada 2025 del circuito ATP con MongoDB. Se carga el dataset, se realizan consultas de inserción, actualización, proyección y filtrado y consultas con el pipeline de agregación y, como parte adicional, se representan algunos resultados en gráficas desde Python.

El análisis parte de la siguiente pregunta:

*¿Fue la temporada 2025 cosa de dos jugadores?*

Alcaraz y Sinner se repartieron los cuatro Grand Slam de 2025. Además de compararlos con el resto del circuito, se estudia la influencia de la superficie, el número de sets y la altura de los jugadores en los partidos.

Cada apartado incluye la consulta, la captura del resultado y su interpretación.

# 2 Dataset

## 2.1 Origen de los datos

Los datos proceden del repositorio público TML-Database (`https://github.com/Tennismylife/TML-Database`), que recoge los partidos del circuito ATP. Se utiliza el fichero de la temporada 2025: 2944 partidos de 197 torneos jugados entre el 29/12/2024 y el 22/12/2025, entre ellos Grand Slam, Masters 1000, ATP 500, ATP 250, ATP Finals, Copa Davis, United Cup, Laver Cup y Next Gen ATP Finals.

## 2.2 Transformación de CSV a JSON

El fichero original es un CSV con un partido por fila y 49 columnas. Las columnas de cada jugador se repiten para el ganador (`winner_*`, `w_*`) y para el perdedor (`loser_*`, `l_*`).

Se utiliza un script en Python para transformar el fichero csv en un json. Los datos de cada jugador se agrupan en los documentos `ganador` y `perdedor`, y sus estadísticas de saque en el subdocumento `estadisticas`. El resultado, por ejemplo `4-6 6-7(4) 6-4 7-6(3) 7-6(2)`, se separa en el array `sets`, con un documento por set.

En la conversión se tratan los siguientes casos:

- Los valores vacíos se guardan como `null` y los números como entero o decimal.
- La fecha pasa de `20250526` a `2025-05-26`, para convertirla después con `$toDate`.

- En los tiebreaks el CSV solo indica los puntos del jugador que lo pierde, por ejemplo `7-6(4)`. Los del que lo gana se calculan como el máximo entre 7 (10 en el quinto set de los Grand Slam) y los puntos del rival más dos.
- El súper tiebreak de la Copa Davis y la Laver Cup (`[10-8]`) se guarda como un set sin juegos, solo con los puntos del tiebreak.
- Las retiradas (`RET`) y los walkovers (`W/O`) se indican en el campo `final`.
- La última fila, la final de las Next Gen ATP Finals, está incompleta. Se mantiene el partido con las estadísticas vacías.

## 2.3 Estructura de los documentos

Cada documento de la colección `partidos` es un partido. La Tabla 1 recoge los campos principales.

| Campo | Tipo | Descripción |
|---|---|---|
| `torneo` | String | Nombre del torneo |
| `superficie` | String | Superficie de la pista: pista dura, tierra batida o hierba |
| `nivel` | String | Categoría del torneo (G Grand Slam, M Masters 1000, 500, 250, F ATP Finals, D Copa Davis, A otros) |
| `fecha` | String | Fecha de inicio del torneo (no del partido) |
| `ronda` | String | Ronda del partido (R128 … F, RR en fases de grupos) |
| `al_mejor_de` | Int | Número máximo de sets del partido (3 o 5) |
| `resultado` | String | Resultado original del CSV |
| `sets` | Array | Un documento por set: `juegos_ganador`, `juegos_perdedor` y `tiebreak` |
| `final` | String | Cómo termina el partido: completo, retirada o walkover |
| `minutos` | Int | Duración del partido |
| `ganador` / `perdedor` | Object | Nombre, país, mano, altura, edad, ranking, puntos de ranking y estadísticas |
| `...estadisticas` | Object | Aces, dobles faltas, puntos y juegos al saque, primeros saques y bolas de break |

**Tabla 1:** Campos principales de la colección `partidos`

El ranking es el de la semana de inicio del torneo, igual en todas las rondas, y la fecha es también la de inicio del torneo.

## 2.4 Carga en MongoDB

El fichero `atp_partidos_2025.json` se importa con MongoDB Compass en la colección `partidos` de la base de datos `tenis-2025`.

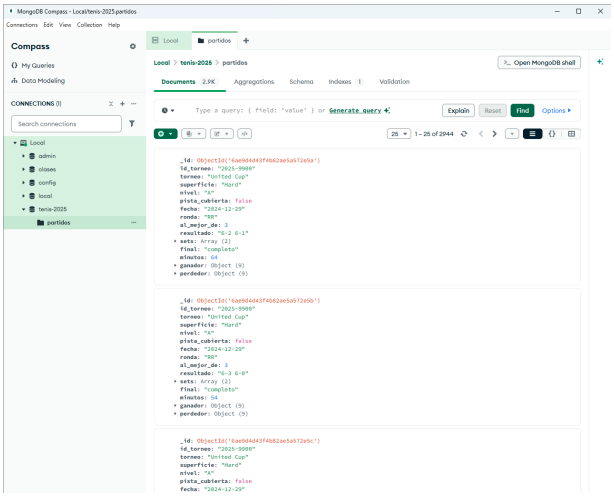


**Figura 1:** Colección `partidos` después de la importación

Desde la consola se comprueban el número de documentos y la estructura de un partido.

## Consulta

```
use tenis-2025

db.partidos.countDocuments({})

db.partidos.findOne()
```

## Resultado

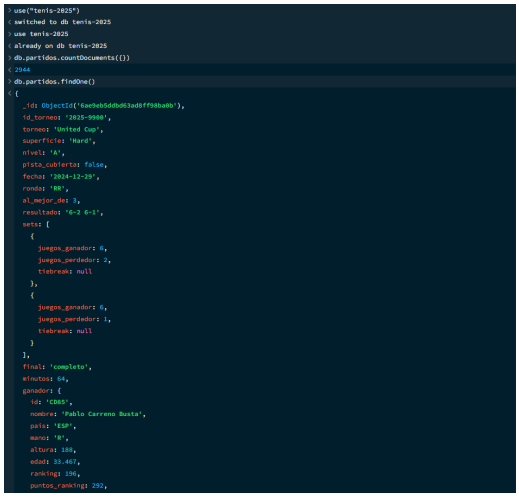


**Figura 2:** Número de documentos y estructura de un partido

## Interpretación

La colección tiene los 2944 partidos del fichero. En el primer documento, un partido

de la United Cup, se ven el array `sets` con un documento por set y el subdocumento `ganador` con los datos del jugador. La superficie aparece todavía en inglés y se traduce en el apartado 3.1.

# 3 Inserción, Actualización, Proyección y Filtrado

## 3.1. Traducción de las superficies

Las superficies vienen en inglés (Hard, Clay y Grass) y se traducen con un `updateMany` por superficie.

**Consulta**

```
db.partidos.distinct("superficie")

var query = { "superficie": "Hard" }
var operacion = { $set: { "superficie": "Dura" } }
db.partidos.updateMany( query, operacion )

var query = { "superficie": "Clay" }
var operacion = { $set: { "superficie": "Tierra" } }
db.partidos.updateMany( query, operacion )

var query = { "superficie": "Grass" }
var operacion = { $set: { "superficie": "Hierba" } }
db.partidos.updateMany( query, operacion )

db.partidos.distinct("superficie")
```

**Resultado**




**Figura 3:** Superficies antes y después de la actualización

### Interpretación

Se modifican 1860 partidos en pista dura, 787 en tierra y 297 en hierba, 2944 en total. La pista dura supone casi dos tercios de los partidos y la hierba un 10 %.

## 3.2. Partidos con y sin estadísticas

Las estadísticas de saque faltan en algunos partidos, siempre todas a la vez, por lo que basta con comprobar los aces del ganador. Se añade el campo `con_estadisticas` para filtrar estos partidos.

### Consulta

```
var query = { "ganador.estadisticas.aces": null }
db.partidos.countDocuments( query )

var operacion = { $set: { "con_estadisticas": false } }
db.partidos.updateMany( query, operacion )

var query = { "con_estadisticas": { $exists: false } }
var operacion = { $set: { "con_estadisticas": true } }
db.partidos.updateMany( query, operacion )
```

### Resultado

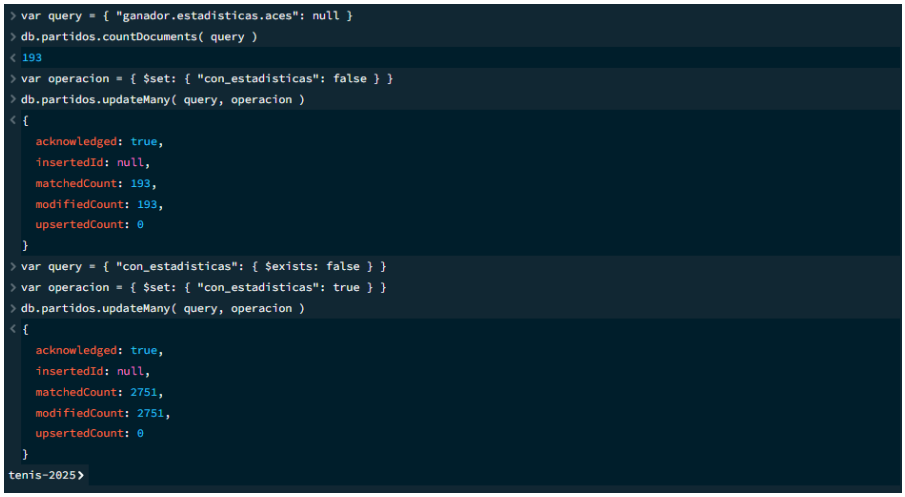



**Figura 4:** Partidos marcados con y sin estadísticas

### Interpretación

193 partidos no tienen estadísticas (6.6 %) y 2751 sí. La segunda actualización usa `$exists: false` porque, tras la primera, solo los partidos con estadísticas no tienen el campo. Las consultas sobre el saque se filtran con `con_estadisticas: true`.

## 3.3. Colección de niveles de torneo

Se crea la colección `niveles` con el nombre de cada código de nivel y los puntos del campeón, que se usa después en un `$lookup`.

### Consulta

```
var array_niveles = [
    { "codigo": "G", "nombre": "Grand Slam", "puntos_campeon": 2000 },
    { "codigo": "F", "nombre": "ATP Finals", "puntos_campeon": 1500 },
    { "codigo": "M", "nombre": "Masters 1000", "puntos_campeon": 1000 },
    { "codigo": "500", "nombre": "ATP 500", "puntos_campeon": 500 },
    { "codigo": "250", "nombre": "ATP 250", "puntos_campeon": 250 },
    { "codigo": "D", "nombre": "Copa Davis" },
    { "codigo": "A", "nombre": "Otros (United Cup, Laver Cup, Next Gen)" }
]
db.niveles.insertMany( array_niveles )
db.niveles.find()
```

### Resultado

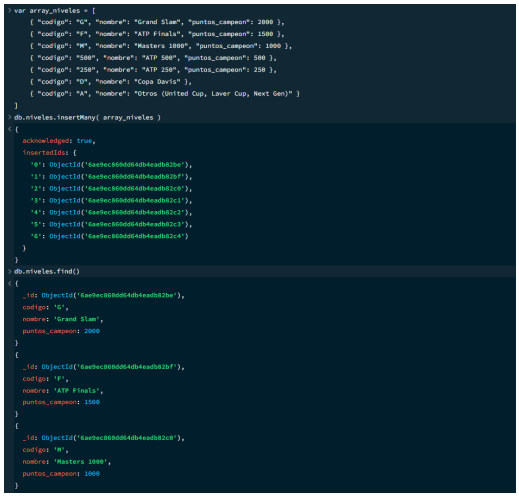


**Figura 5:** Inserción de la colección `niveles`

### Interpretación

Se insertan los 7 niveles. La Copa Davis y el nivel de otras competiciones no llevan `puntos_campeon`, ya que no reparten puntos fijos por título.

## 3.4. Inserción, modificación y borrado de un partido

Se inserta el primer partido de la temporada 2026 con solo algunos campos, se completa con su duración y sus sets y se borra.

## Consulta

```
var ganador = { "nombre": "Sebastian Baez", "pais": "ARG", "ranking": 45 }
var perdedor = { "nombre": "Jaume Munar", "pais": "ESP", "ranking": 33 }
var nuevo_partido = { "torneo": "United Cup", "superficie": "Dura", "nivel":
    "A", "fecha": "2026-01-02", "ronda": "RR", "resultado": "6-4 6-4",
    "ganador": ganador, "perdedor": perdedor }
db.partidos.insertOne( nuevo_partido )

var query = { "fecha": "2026-01-02" }
db.partidos.find( query )

var operacion = { $set: { "minutos": 103 } }
db.partidos.updateOne( query, operacion )

var set1 = { "juegos_ganador": 6, "juegos_perdedor": 4, "tiebreak": null }
var set2 = { "juegos_ganador": 6, "juegos_perdedor": 4, "tiebreak": null }
var operacion = { $push: { "sets": { $each: [ set1, set2 ] } } }
db.partidos.updateOne( query, operacion )
db.partidos.find( query )

db.partidos.deleteOne( query )
db.partidos.countDocuments({})
```

## Resultado

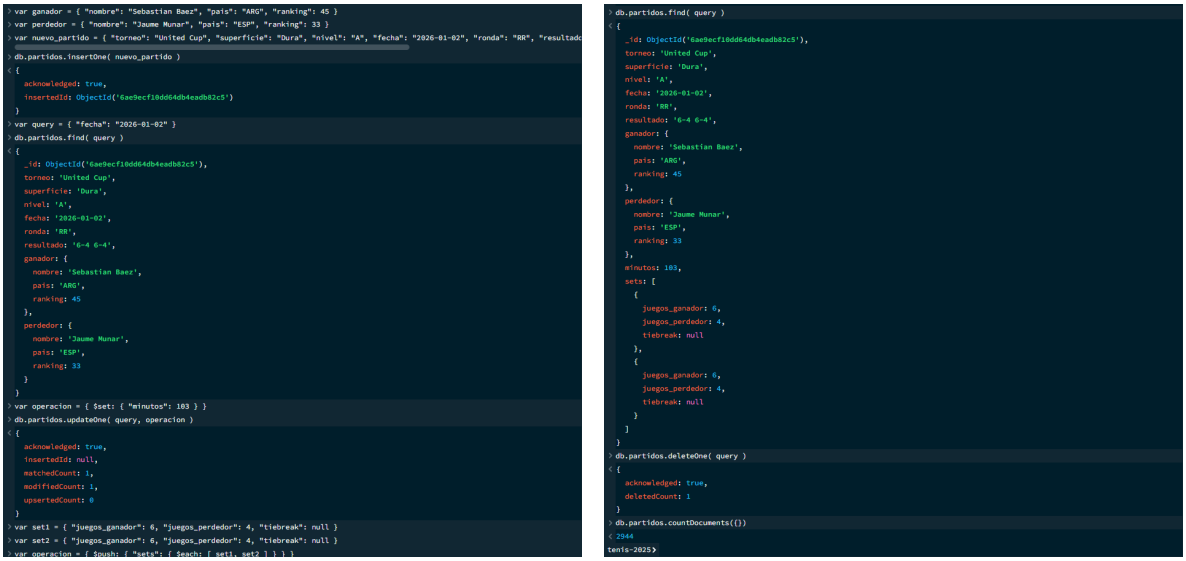


**Figura 6:** Inserción, actualización y borrado de un partido de 2026

## Interpretación

`$set` añade el campo `minutos`, que no existía, y `$push` con `$each` crea el array `sets` con los dos sets. Tras el `deleteOne` vuelven a quedar 2944 partidos.

## 3.5. Finales de los Grand Slam

### Consulta

```
var query = { "nivel": "G", "ronda": "F" }
var proyeccion = { "_id": 0, "torneo": 1, "ganador.nombre": 1,
    "perdedor.nombre": 1, "resultado": 1, "minutos": 1 }
var opcion = { "fecha": 1 }
db.partidos.find( query, proyeccion ).sort( opcion )
```

### Resultado

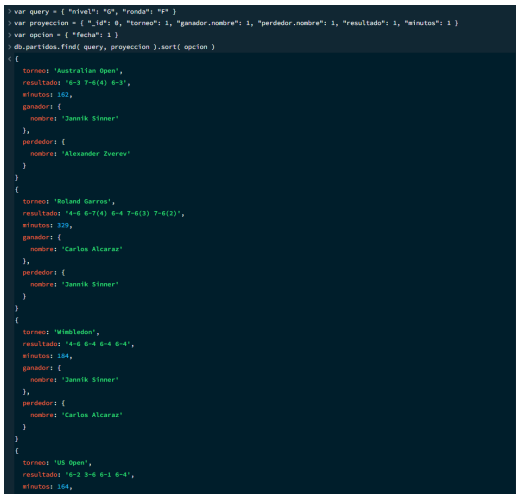



**Figura 7:** Finales de los cuatro Grand Slam de 2025

### Interpretación

Sinner gana el Open de Australia y Wimbledon, y Alcaraz Roland Garros y el US Open. Tres de las cuatro finales son entre ellos; la de Australia la juega Sinner contra Zverev.

La final de Roland Garros dura 329 minutos, frente a los 162-184 de las demás. Alcaraz remonta dos sets en contra y gana el quinto en un tiebreak a 10 puntos.

## 3.6. Partidos entre Alcaraz y Sinner

### Consulta

```
var query1 = { "ganador.nombre": "Carlos Alcaraz", "perdedor.nombre": "Jannik
    Sinner" }
var query2 = { "ganador.nombre": "Jannik Sinner", "perdedor.nombre": "Carlos
    Alcaraz" }
var logic = { $or: [ query1, query2 ] }
var proyeccion = { "_id": 0, "torneo": 1, "ronda": 1, "superficie": 1,
    "ganador.nombre": 1, "resultado": 1 }
var opcion = { "fecha": 1 }
db.partidos.find( logic, proyeccion ).sort( opcion )
```

### Resultado

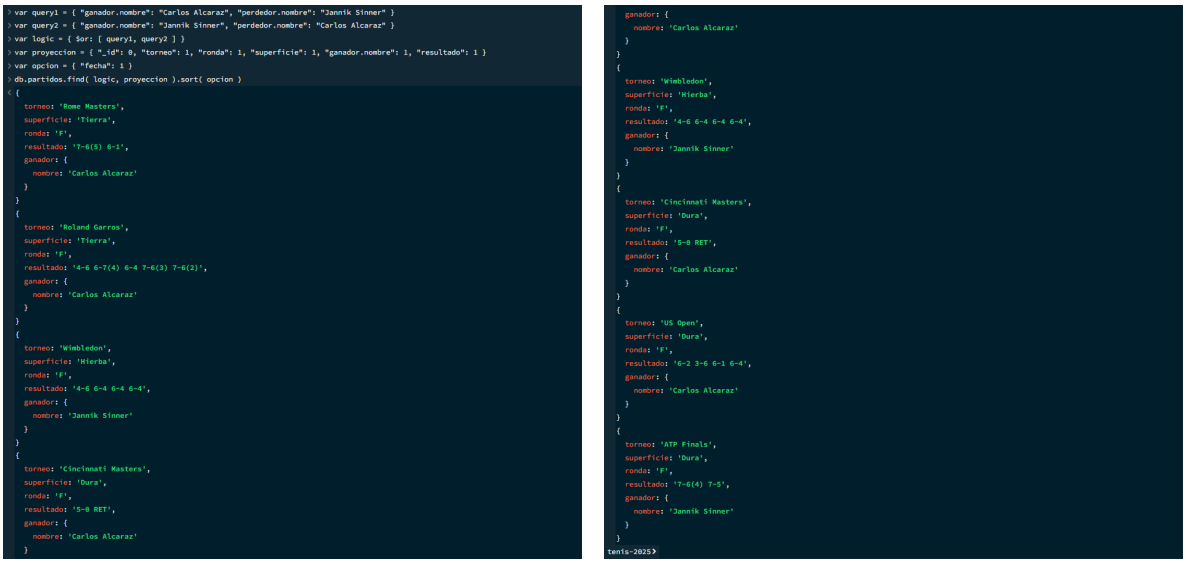



**Figura 8:** Partidos entre Alcaraz y Sinner en 2025

### Interpretación

Se enfrentan seis veces, todas en finales: Roma, Roland Garros, Wimbledon, Cincinnati, US Open y ATP Finals, en las tres superficies. Alcaraz gana cuatro y Sinner dos. La victoria de Alcaraz en Cincinnati es por retirada de Sinner con 5-0 en el primer set.

## 3.7. Partidos más largos de la temporada

### Consulta

```
var query = { "minutos": { $ne: null } }
var proyeccion = { "_id": 0, "torneo": 1, "ronda": 1, "ganador.nombre": 1,
    "perdedor.nombre": 1, "resultado": 1, "minutos": 1 }
var opcion = { "minutos": -1 }
db.partidos.find( query, proyeccion ).sort( opcion ).limit(5)
```

### Resultado

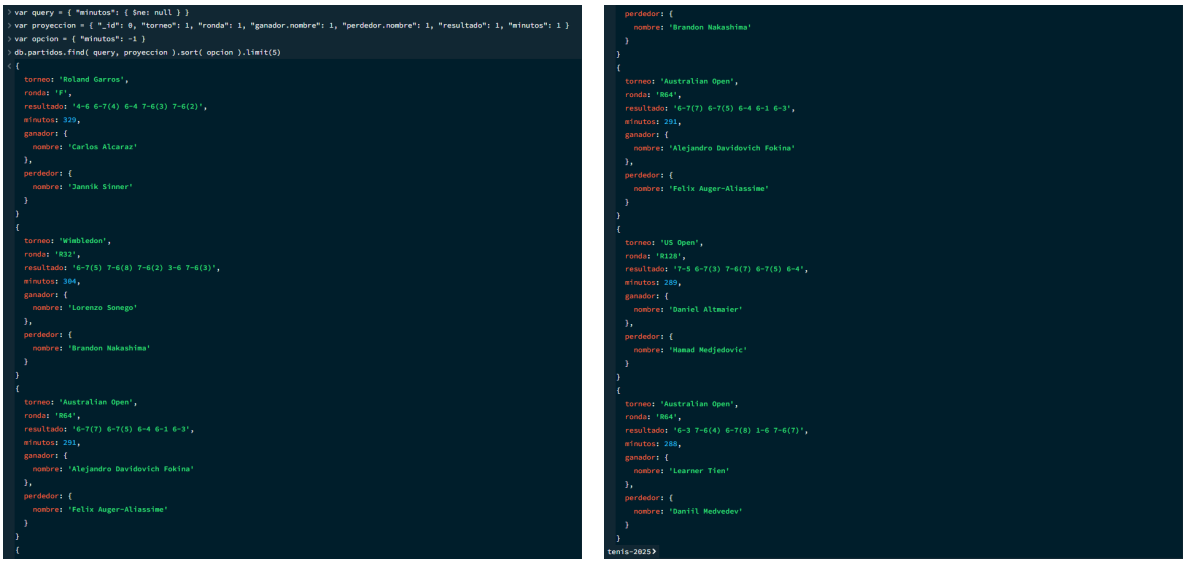



**Figura 9:** Los 5 partidos más largos de 2025

### Interpretación

Los cinco son partidos de Grand Slam a cinco sets, el único torneo al mejor de cinco. Salvo la final de Roland Garros, son de primeras rondas, y todos tienen al menos dos tiebreaks.

## 3.8. Consultas sobre el array de sets

Se cuentan los partidos a cinco sets y los partidos en los que el ganador perdió algún set 6-7, con y sin `$elemMatch`.

### Consulta

```
var query = { "sets": { $size: 5 } }
db.partidos.countDocuments( query )

var query = { "sets.juegos_ganador": 6, "sets.juegos_perdedor": 7 }
db.partidos.countDocuments( query )

var query = { "sets": { $elemMatch: { "juegos_ganador": 6, "juegos_perdedor": 7
    } } }
db.partidos.countDocuments( query )
```

### Resultado

```
> var query = { "sets": { $size: 5 } }
> db.partidos.countDocuments( query )
< 101
> var query = { "sets.juegos_ganador": 6, "sets.juegos_perdedor": 7 }
> db.partidos.countDocuments( query )
< 381
> var query = { "sets": { $elemMatch: { "juegos_ganador": 6, "juegos_perdedor": 7 } } }
> db.partidos.countDocuments( query )
< 281
tenis-2025>
```

**Figura 10:** Partidos a cinco sets y comparación con y sin `$elemMatch`

### Interpretación

101 partidos llegan al quinto set. Sin `$elemMatch` salen 381 partidos y con `$elemMatch` 281. Sin `$elemMatch` cada condición puede cumplirse en un set distinto: un partido `6-4 5-7 6-3` cuenta aunque ningún set acabe 6-7. Con `$elemMatch` las dos condiciones se aplican al mismo set, por lo que los 100 partidos de diferencia son falsos positivos.

# 4 Pipeline de Agregación

## 4.1. Partidos y duración media por superficie

### Consulta

```
var query1 = { "_id": "$superficie", "partidos": { $sum: 1 }, "media_minutos": {
    $avg: "$minutos" } }
var fase1 = { $group: query1 }
var query2 = { "partidos": -1 }
var fase2 = { $sort: query2 }
var etapas = [ fase1, fase2 ]
db.partidos.aggregate( etapas )
```

### Resultado

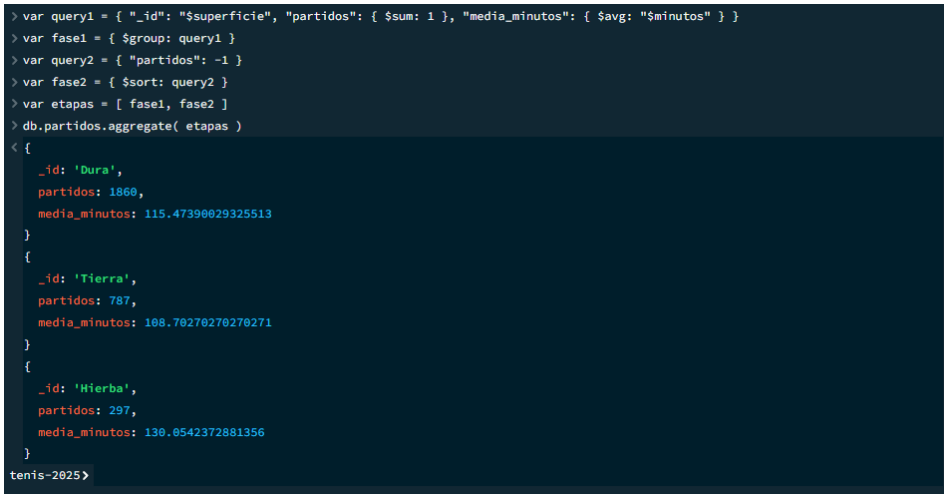



**Figura 11:** Partidos y duración media por superficie

### Interpretación

La hierba tiene la mayor duración media, 130 minutos, frente a 115 en pista dura y 109 en tierra. En la siguiente consulta se separa por número de sets.

## 4.2. Duración media por superficie y número de sets

### Consulta

```
var query1 = { "minutos": { $ne: null } }
var fase1 = { $match: query1 }
var grupo = { "superficie": "$superficie", "al_mejor_de": "$al_mejor_de" }
var query2 = { "_id": grupo, "partidos": { $sum: 1 }, "media_minutos": { $avg:
    "$minutos" } }
var fase2 = { $group: query2 }
var query3 = { "_id.al_mejor_de": 1, "media_minutos": -1 }
var fase3 = { $sort: query3 }
var etapas = [ fase1, fase2, fase3 ]
db.partidos.aggregate( etapas )
```

### Resultado

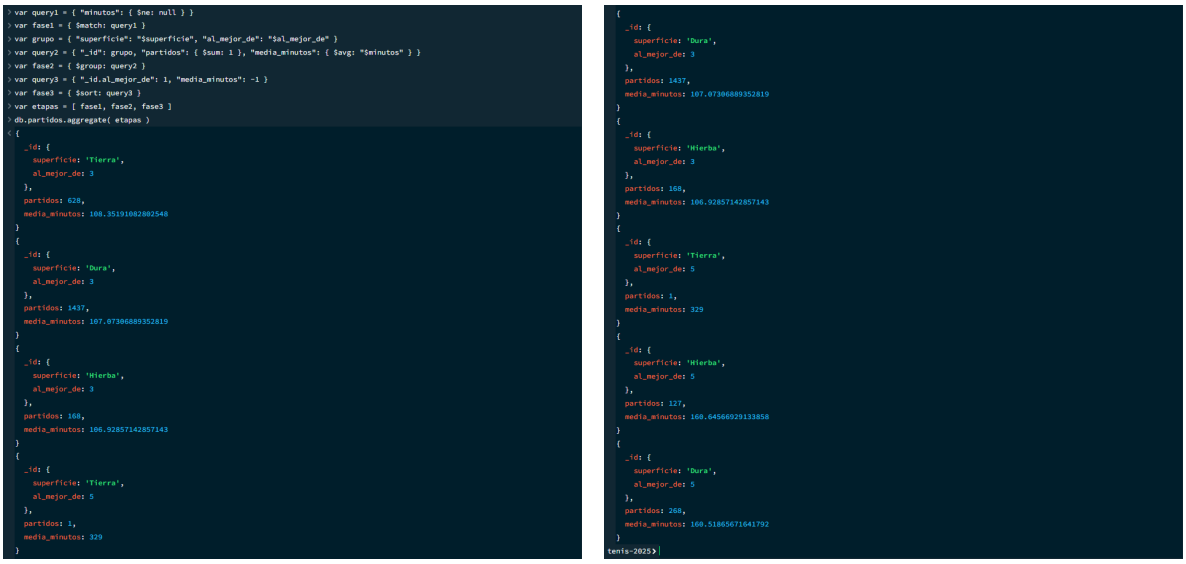



**Figura 12:** Duración media por superficie y número máximo de sets

### Interpretación

Al mejor de tres sets la hierba tiene los partidos más cortos (106.9 minutos), con las tres superficies muy próximas. La media de la consulta anterior está influida por Wimbledon: 127 de los 297 partidos en hierba son al mejor de cinco sets.

En tierra solo hay un partido al mejor de cinco con duración, aunque Roland Garros tiene 127, ya que en este torneo solo la final tiene el campo `minutos`. La media de la tierra no incluye los partidos de Roland Garros.

## 4.3. Títulos y puntos por jugador

Se une cada final con la colección `niveles` mediante `$lookup` para obtener los puntos de cada título.

### Consulta

```
var query1 = { "ronda": "F" }
var fase1 = { $match: query1 }
var query2 = { from: "niveles", localField: "nivel", foreignField: "codigo", as:
    "info_nivel" }
var fase2 = { $lookup: query2 }
var fase3 = { $unwind: "$info_nivel" }
var query4 = { "_id": "$ganador.nombre", "titulos": { $sum: 1 }, "puntos": {
    $sum: "$info_nivel.puntos_campeon" }, "torneos": { $push: "$torneo" } }
var fase4 = { $group: query4 }
var query5 = { "puntos": -1 }
var fase5 = { $sort: query5 }
var fase6 = { $limit: 5 }
var etapas = [ fase1, fase2, fase3, fase4, fase5, fase6 ]
db.partidos.aggregate( etapas )
```

### Resultado

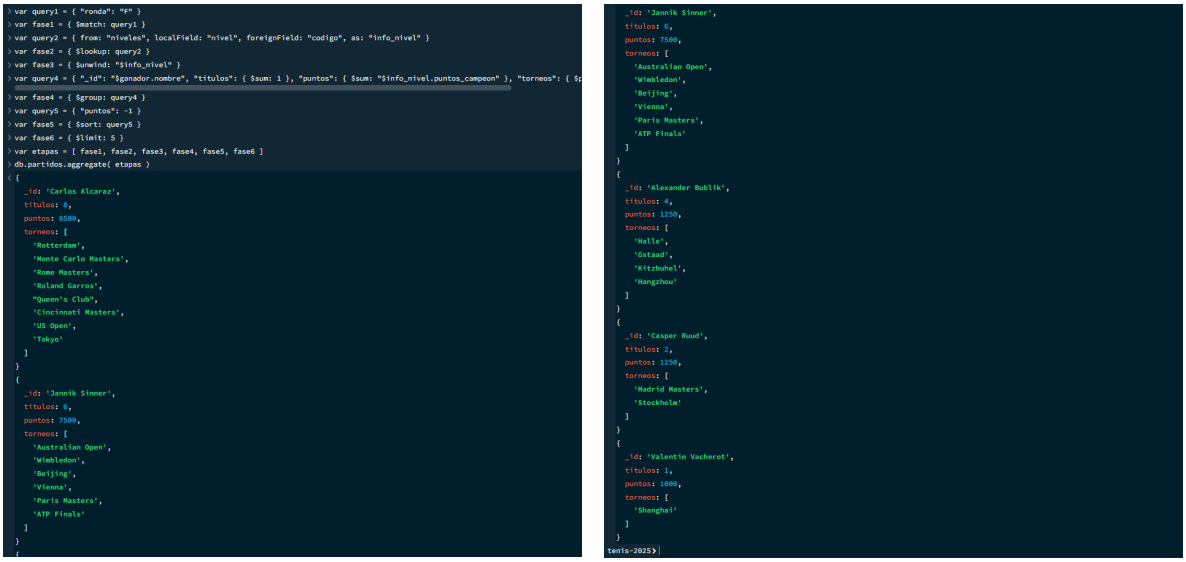



**Figura 13:** Jugadores con más puntos por títulos

### Interpretación

Alcaraz suma 8 títulos y 8500 puntos y Sinner 6 títulos y 7500 puntos, 16000 entre los dos frente a los 3500 de los tres siguientes. Alcaraz gana títulos en las tres superficies y Sinner concentra los suyos en torneos de mayor categoría.

Bublik, con 4 títulos, suma los mismos puntos que Ruud con 2. Vacherot entra en los

cinco primeros al ganar el Masters 1000 de Shanghái con el ranking 202. Solo se cuentan los puntos del campeón, no los de cada ronda.

## 4.4. Balance de victorias de todos los jugadores

Cada jugador aparece como ganador o como perdedor, por lo que cada partido se transforma en un array con los dos jugadores y se separa con `$unwind`. El resultado se guarda con `$out` en la colección `jugadores`.

### Consulta

```
var jugador1 = { "nombre": "$ganador.nombre", "pais": "$ganador.pais",
    "victoria": 1 }
var jugador2 = { "nombre": "$perdedor.nombre", "pais": "$perdedor.pais",
    "victoria": 0 }
var query1 = { "_id": 0, "jugadores": [ jugador1, jugador2 ] }
var fase1 = { $project: query1 }
var fase2 = { $unwind: "$jugadores" }
var query3 = { "_id": "$jugadores.nombre", "pais": { $first: "$jugadores.pais"
    }, "partidos": { $sum: 1 }, "victorias": { $sum: "$jugadores.victoria" } }
var fase3 = { $group: query3 }
var porcentaje = { $multiply: [ { $divide: [ "$victorias", "$partidos" ] }, 100
    ] }
var query4 = { "porcentaje": porcentaje }
var fase4 = { $addFields: query4 }
var fase5 = { $out: "jugadores" }
var etapas = [ fase1, fase2, fase3, fase4, fase5 ]
db.partidos.aggregate( etapas )
```

### Resultado

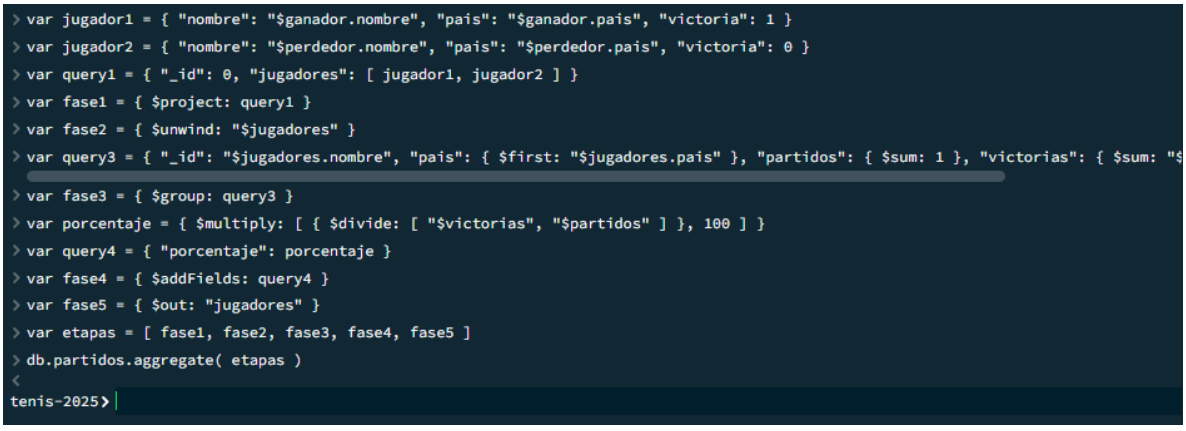



**Figura 14:** Creación de la colección `jugadores` con `$out`

Sobre la colección `jugadores` se obtienen los mejores porcentajes de victoria con un mínimo de 40 partidos.

### Consulta

```
db.jugadores.countDocuments({})
var query = { "partidos": { $gte: 40 } }
var opcion = { "porcentaje": -1 }
db.jugadores.find( query ).sort( opcion ).limit(10)
```

### Resultado

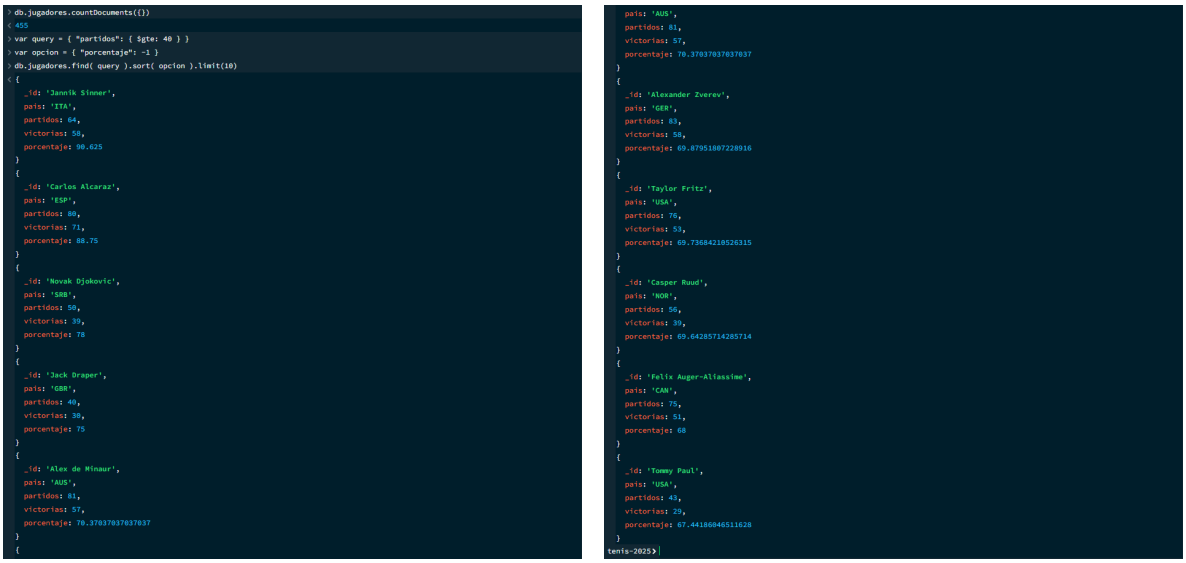



**Figura 15:** Mejores porcentajes de victoria con al menos 40 partidos

### Interpretación

La colección tiene 455 jugadores. Sinner tiene el mejor porcentaje (90.6 %) y Alcaraz el segundo (88.75 %), aunque Alcaraz gana más partidos, 71 frente a 58, al jugar 16 más (apartado 4.7). Djokovic es tercero con un 78 %. Zverev gana los mismos partidos que Sinner, pero en 83 partidos, y se queda en un 69.9 %.

## 4.5. Porcentaje de sets que acaban en tiebreak por superficie

### Consulta

```
var fase1 = { $unwind: "$sets" }
var query2 = { "sets.juegos_ganador": { $ne: null } }
var fase2 = { $match: query2 }
var es_tiebreak = { $cond: [ { $ne: [ "$sets.tiebreak", null ] }, 1, 0 ] }
var query3 = { "_id": "$superficie", "sets": { $sum: 1 }, "tiebreaks": { $sum:
    es_tiebreak } }
var fase3 = { $group: query3 }
var porcentaje = { $multiply: [ { $divide: [ "$tiebreaks", "$sets" ] }, 100 ] }
var query4 = { "porcentaje": porcentaje }
var fase4 = { $addFields: query4 }
var query5 = { "porcentaje": -1 }
var fase5 = { $sort: query5 }
var etapas = [ fase1, fase2, fase3, fase4, fase5 ]
db.partidos.aggregate( etapas )
```

### Resultado

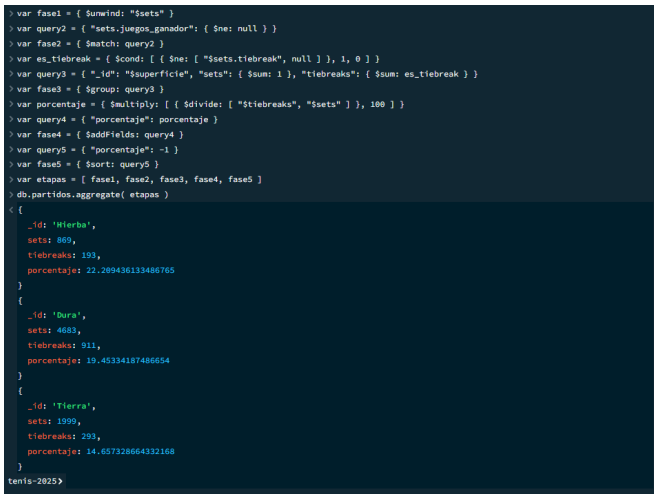



**Figura 16:** Sets y tiebreaks por superficie

### Interpretación

En hierba acaba en tiebreak el 22.2 % de los sets, en pista dura el 19.5 % y en tierra el 14.7 %, en línea con la mayor ventaja del saque en las superficies rápidas. El `$match` excluye los súper tiebreaks, que no tienen juegos.

## 4.6. Aces según la altura del jugador

Se agrupan los jugadores por tramos de altura con `$bucket` y se calcula la media de aces por partido.

### Consulta

```
var jugador1 = { "altura": "$ganador.altura", "aces":
    "$ganador.estadisticas.aces" }
var jugador2 = { "altura": "$perdedor.altura", "aces":
    "$perdedor.estadisticas.aces" }
var query1 = { "con_estadisticas": true }
var fase1 = { $match: query1 }
var query2 = { "_id": 0, "jugadores": [ jugador1, jugador2 ] }
var fase2 = { $project: query2 }
var fase3 = { $unwind: "$jugadores" }
var query4 = { "jugadores.altura": { $ne: null } }
var fase4 = { $match: query4 }
var fase5 = {
    $bucket: {
        groupBy: "$jugadores.altura",
        boundaries: [ 165, 175, 180, 185, 190, 195, 200, 215 ],
        default: "Otros",
        output: {
            "partidos": { $sum: 1 },
            "media_aces": { $avg: "$jugadores.aces" }
        }
    }
}
var etapas = [ fase1, fase2, fase3, fase4, fase5 ]
db.partidos.aggregate( etapas )
```

### Resultado

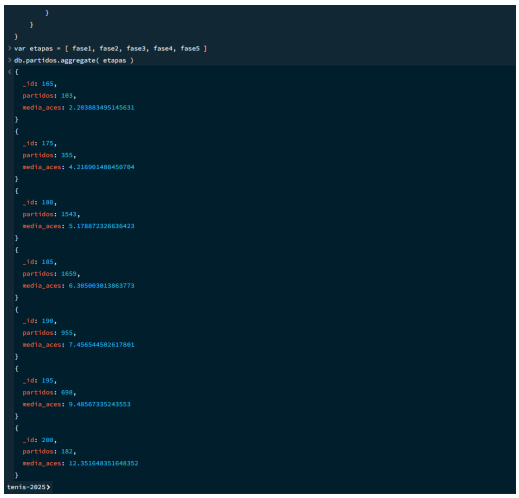



**Figura 17:** Media de aces por partido según la altura

### Interpretación

La media de aces crece en todos los tramos, de 2.2 por partido por debajo de 1.75 m a 12.4 por encima de 2 m. El tramo con más partidos es el de 1.85 a 1.89 m.

## 4.7. Victorias de Alcaraz y Sinner por mes

### Consulta

```
var query1 = { "ganador.nombre": { $in: [ "Carlos Alcaraz", "Jannik Sinner" ] } }
var fase1 = { $match: query1 }
var fase2 = { $addFields: { "fecha_date": { $toDate: "$fecha" } } }
var grupo = { "jugador": "$ganador.nombre", "mes": { $month: "$fecha_date" } }
var query3 = { "_id": grupo, "victorias": { $sum: 1 } }
var fase3 = { $group: query3 }
var query4 = { "_id.jugador": 1, "_id.mes": 1 }
var fase4 = { $sort: query4 }
var etapas = [ fase1, fase2, fase3, fase4 ]
db.partidos.aggregate( etapas )
```

### Resultado

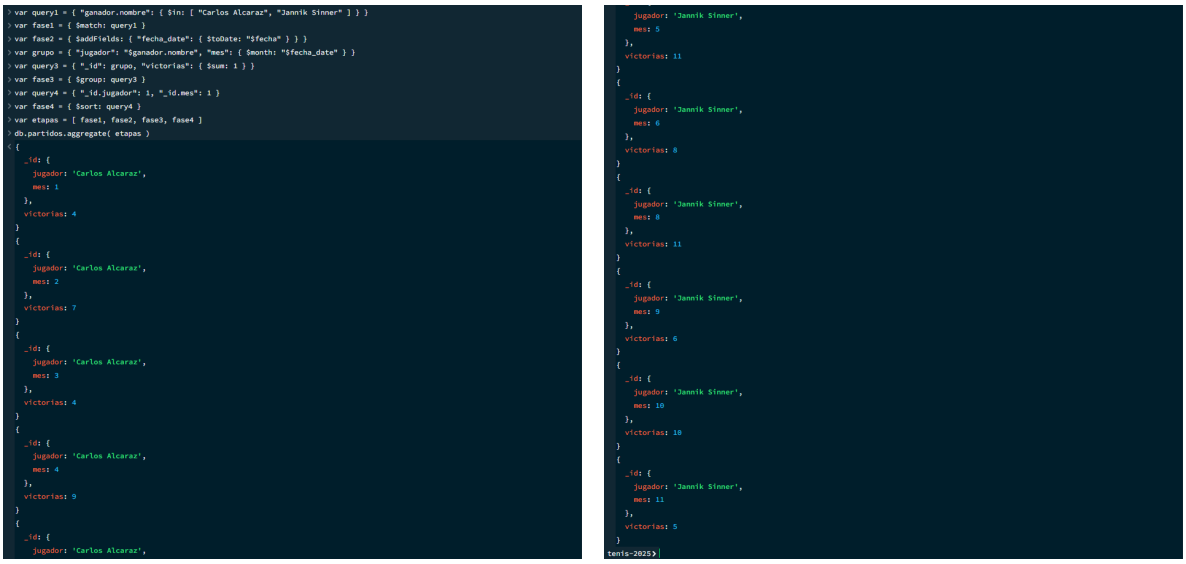


**Figura 18:** Victorias de Alcaraz y Sinner por mes

### Interpretación

Sinner no tiene victorias de febrero a abril por su sanción de tres meses y vuelve en mayo con 11. En esos meses Alcaraz suma 20 victorias, que explican buena parte de la diferencia de partidos ganados.

Ninguno tiene victorias en julio, aunque Sinner gana Wimbledon, porque la fecha es la de inicio del torneo (30 de junio). En octubre Sinner suma 10 victorias y Alcaraz ninguna.

# 5 Visualización con Python

Como parte adicional, el notebook `graficas_tenis.ipynb` se conecta a la base de datos con pymongo, lanza algunas de las agregaciones anteriores y representa los resultados con matplotlib. Las agregaciones son las mismas que en la consola, con las claves entre comillas y `None` en lugar de `null`.

```
import os
import pandas as pd
import matplotlib.pyplot as plt
from pymongo import MongoClient

cliente = MongoClient("mongodb://localhost:27017")
db = cliente["tenis-2025"]

os.makedirs("graficas", exist_ok=True)

print("Partidos:", db.partidos.count_documents({}))
print("Jugadores:", db.jugadores.count_documents({}))
```

Los meses sin victorias no aparecen en la agregación, por lo que se parte de dos listas de 12 ceros que se rellenan con los resultados.

```
query1 = {"ganador.nombre": {"$in": ["Carlos Alcaraz", "Jannik Sinner"]}}
fase1 = {"$match": query1}
fase2 = {"$addFields": {"fecha_date": {"$toDate": "$fecha"}}}
grupo = {"jugador": "$ganador.nombre", "mes": {"$month": "$fecha_date"}}
query3 = {"_id": grupo, "victorias": {"$sum": 1}}
fase3 = {"$group": query3}
query4 = {"_id.jugador": 1, "_id.mes": 1}
fase4 = {"$sort": query4}
etapas = [fase1, fase2, fase3, fase4]

resultado = list(db.partidos.aggregate(etapas))

# los meses sin victorias no salen en la agregacion, asi que empiezo con todo a 0
meses = list(range(1, 13))
victorias_alcaraz = [0] * 12
victorias_sinner = [0] * 12

for doc in resultado:
    mes = doc["_id"]["mes"]
    if doc["_id"]["jugador"] == "Carlos Alcaraz":
        victorias_alcaraz[mes - 1] = doc["victorias"]
    else:
        victorias_sinner[mes - 1] = doc["victorias"]

print("Alcaraz:", victorias_alcaraz)
print("Sinner: ", victorias_sinner)
```

```
plt.plot(meses, victorias_alcaraz, "o-", label="Alcaraz")
plt.plot(meses, victorias_sinner, "s-", label="Sinner")
plt.xticks(meses)
plt.xlabel("Mes")
plt.ylabel("Victorias")
plt.title("Victorias por mes en 2025")
plt.legend()
plt.grid(True)
plt.savefig("graficas/victorias_mes.png")
plt.show()
```

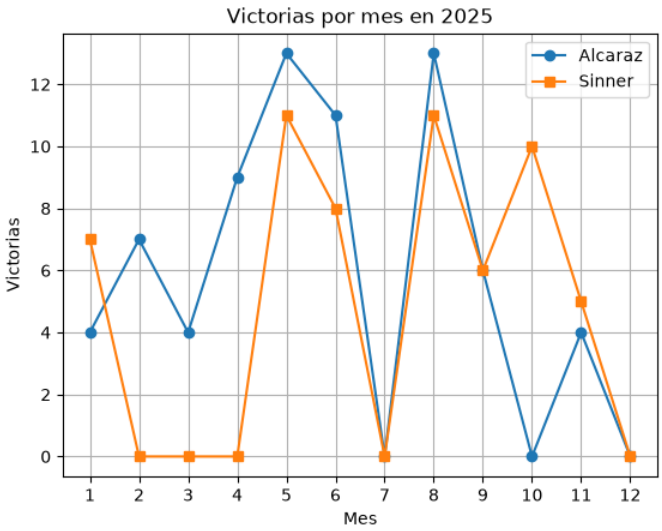



**Figura 19:** Victorias de Alcaraz y Sinner por mes en 2025

Se observa el periodo sin competir de Sinner y un número de victorias similar de ambos en el resto de meses, salvo en octubre.

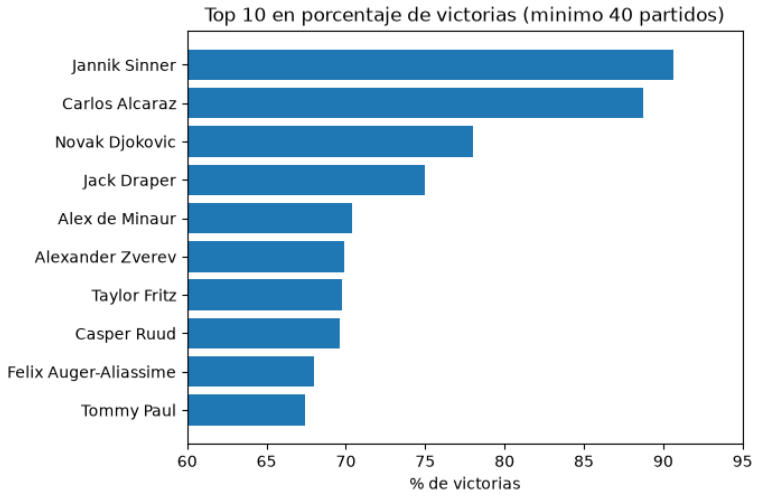



**Figura 20:** Top 10 en porcentaje de victorias (mínimo 40 partidos)

Esta gráfica se obtiene de la colección `jugadores`, sin repetir la agregación.

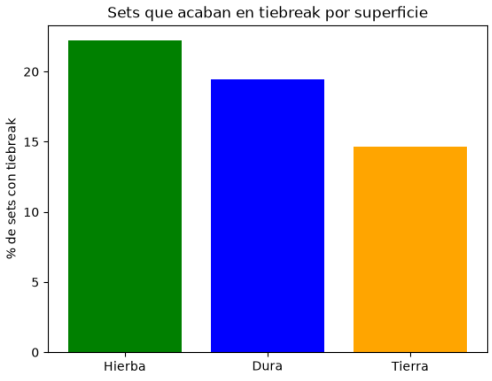



**Figura 21:** Tiebreaks por superficie

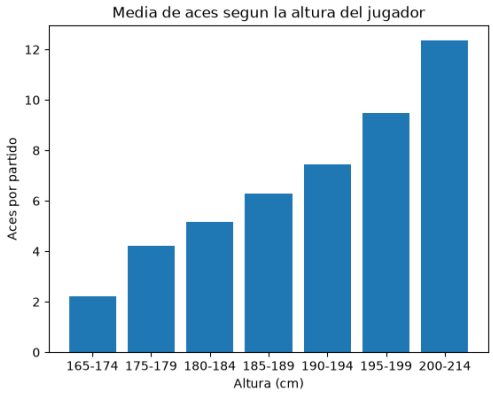



**Figura 22:** Aces por partido según la altura

Las dos gráficas muestran el peso del saque: más tiebreaks en las superficies rápidas y más aces a mayor altura.

# 6 Conclusiones

Los datos indican que la temporada 2025 fue en gran medida cosa de dos jugadores. Alcaraz y Sinner se reparten los cuatro Grand Slam, juegan seis finales entre ellos, son los únicos con más de 40 partidos por encima del 80 % de victorias y suman más del cuádruple de puntos en títulos que los tres siguientes. Entre ellos la temporada está igualada: Alcaraz gana más partidos y títulos y Sinner tiene mejor porcentaje pese a pasar tres meses sin competir.

Fuera de ellos, el ranking no siempre anticipa al ganador, como muestra el título de Vacherot en Shanghái con el ranking 202.

La superficie influye en el juego: en hierba hay más tiebreaks y en tierra menos, y los aces aumentan con la altura del jugador. La duración depende sobre todo del número de sets, y la mayor media de la hierba se debe a Wimbledon.

En cuanto a las limitaciones del dataset, falta la duración de casi todo Roland Garros y las estadísticas de 193 partidos, y el ranking y la fecha son los de la semana de inicio de cada torneo.